2.2 当前整体框架：主干 + 两条控制支路

输入模态

- X_i 历史序列
- U_i 时间信息
- 原始文本

两条支路

A 文本构造支路

scale-aware RAG → CoT → 条件表示

B 控制支路

scale router → 多分辨率训练 + 自适应 guidance

核心创新： 两条支路最终都作用于条件扩散预测

总体逻辑流程

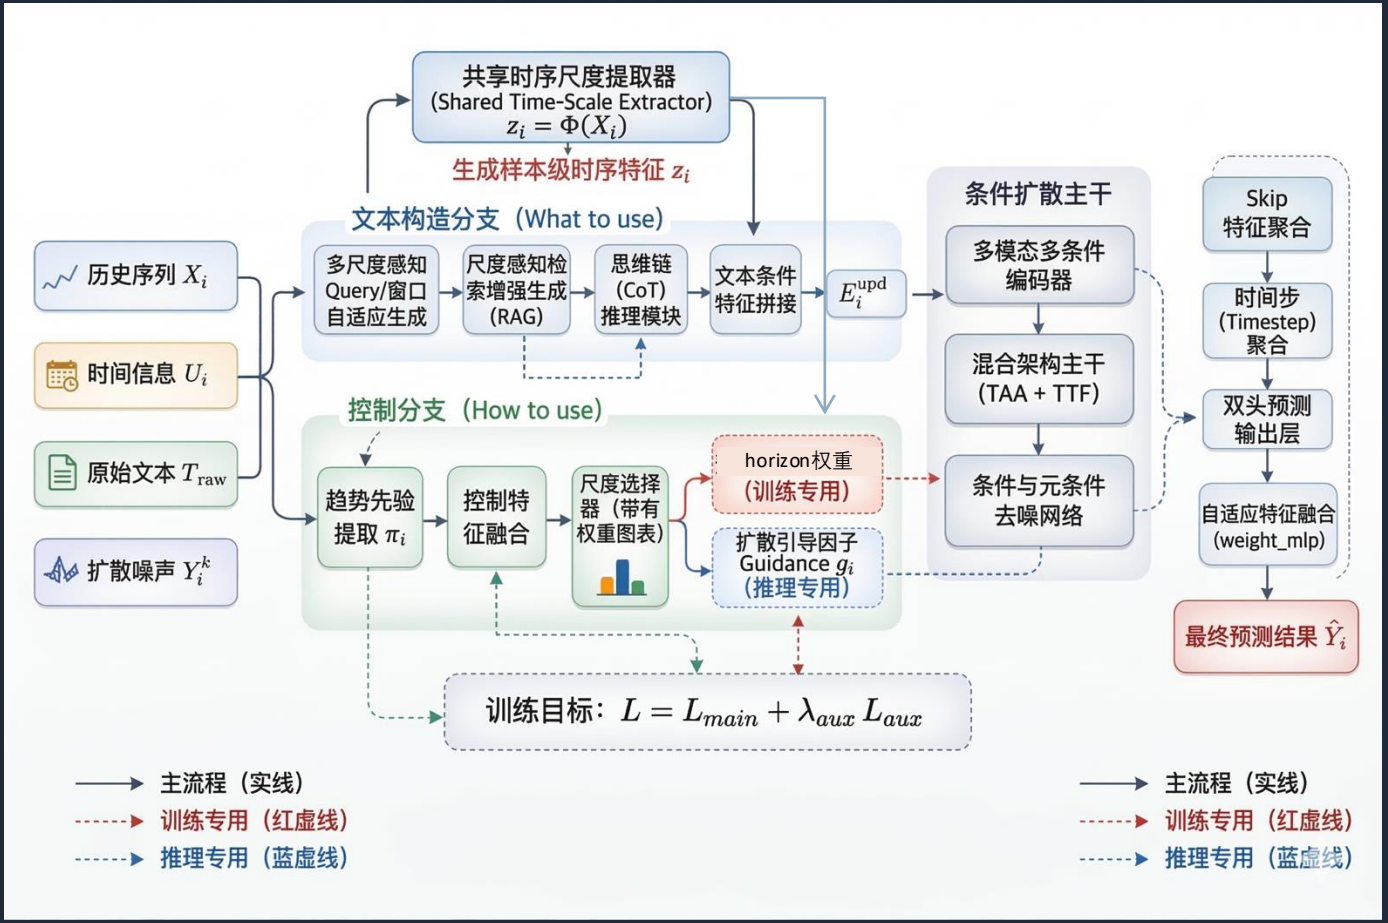

本文不是在原模型上简单再加一个模块，而是把时间尺度变成连接文本构造、训练监督和推理 guidance 的统一线索

3. Step 1：从历史序列中提取时间尺度表征

提取过程

首先从历史序列中提取样本的**尺度相关特征**，这些特征反映了序列在不同时间尺度上的行为模式。

特征维度

- 趋势强度
- 局部波动
- 差分变化
- 加速度
- 相对波动率

核心公式

$$z_i = \Phi(X_i)$$

历史序列：

$$X_i = [x_{i,1}, x_{i,2}, \dots, x_{i,H}]$$

尺度表征： zi 是后续所有动作的起点

目标判断

这一步的目标不是直接预测，而是判断当前样本更偏向：

短期扰动
高频波动，局部变化明显

中期过渡
趋势与波动并存

长期趋势
结构性变化，方向性强

关键说明

强调 zi 是后续所有动作的起点，但不是一个单独变量直接控制所有模块；后续会分化为**文本构造信号**和**router 控制信号**两种用途。

→ 尺度表征 z_i 将分化为两条路径：文本构造支路和控制支路

3.2 Step 2：尺度感知的文本窗口与 RAG 检索

处理流程

1. **生成文本构造信号**
   由尺度表征生成
2. **决定文本窗口长度**
   根据信号动态调整
3. **构造 Query**
   结合历史序列、时间信息和原始文本
4. **检索证据集合**
   得到与当前样本更匹配的结果

核心公式

文本构造信号：

$$s_i^{rag} = G_{rag}(z_i), \ell_i = \Gamma(s_i^{rag})$$

尺度感知检索：

$$D_i^{rag} = Retrieve\ (\Psi_q(X_i, U_i, T_i^{raw}, s_i^{rag}), C_i(\ell_i))$$

符号解释

s_i^{rag}

文本构造支路中的尺度信号

ℓ_i

文本窗口长度

T_i^{raw}

原始文本片段

D_i^{rag}

检索到的证据集合

核心洞察

时间尺度不是直接替代检索器，而是参与**"文本窗口构造 + query 组织"**，从而使检索结果更贴合当前样本的预测需求。

3.3 Step 3：CoT 把检索证据变成可计算条件

为什么需要 CoT

RAG 返回的是**分散的证据集合**，这些证据仍然是冗余的、碎片化的。

因此需要引入 CoT，把证据整理成**结构化推理摘要**。

核心公式

CoT 推理摘要：

$$c_i = \Psi_{cot}(X_i, U_i, D_i^{rag})$$

趋势先验：

$$\pi_i = \Omega(c_i)$$

可表示为：

$$\pi_i = [direction_i, strength_i, volatility_i]$$

CoT 的双重输出

文本侧

推理摘要（自然语言形式的解释）

控制支路

趋势先验（可计算的中间变量）

CoT 结果不仅是文字解释，还会转成趋势先验 π_i 供后续模块使用。

核心洞察

CoT 不是附加解释层，而是从**"证据"**到**"可计算中间变量"**的关键桥梁。

3.4 Step 4：形成统一文本条件表示

整合需求

最终进入模型的文本条件**不是单一来源**，需要统一整合多个信息来源。

信息来源

1. **原始文本片段** T_i^{raw}
2. **数值摘要** S_i^{num} - 由数值历史得到
3. **尺度提示** s_i^{rag}
4. **检索证据** D_i^{rag} - RAG 证据
5. **CoT 摘要** c_i - 推理摘要

核心公式

统一文本条件表示：

$$E_i^{upd} = Compose\ (T_i^{raw}, S_i^{num}, s_i^{rag}, D_i^{rag}, c_i)$$

T_i^{raw} 原始文本	S_i^{num} 数值摘要
s_i^{rag} 尺度提示	D_i^{rag} RAG 证据
c_i CoT 推理摘要	

关键说明

进入模型的文本条件并不是"只有原始文本"或"只有检索文本"，而是**多个来源的统一融合**。这一步保证文本侧信息完整且结构化。

3.5 Step 5：scale router 驱动多分辨率训练

核心机制

1. 训练时不再把整个预测窗口看成一个整体，而是 **拆成多个时间 band**
2. 对每个 band 分别计算误差，显式区分 **短期、中期、长期** 预测难度
3. router 融合历史序列特征、趋势先验和文本可用性，输出 **样本级时间尺度 band 权重分布**
4. 由" **样本级 router 权重 + 全局 band 难度统计** "共同决定辅助损失的加权方式

回答的问题

对于当前样本，训练时应该 **更关注哪些 horizon band?**

为什么需要

- 如果所有 horizon 使用统一损失，模型只能学到 **平均意义上的预测策略**
- 但不同样本的难点并不相同：有些样本短期波动更强，有些样本长期趋势更明显
- 因此需要 **样本级的时间尺度加权机制**，让训练目标随样本变化而变化

★ scale router 的本质，是让损失函数按样本的时间尺度结构动态重分配到不同 horizon band 上

核心公式

scale router:

$$r_i^{router} = softmax\left(G_{router}(\tilde{z}_i)\right) = (r_{i,1}, r_{i,2}, \dots, r_{i,B})$$

其中 $\tilde{z}_i = \mathrm{Fuse}(X_i, \pi_i, m_i)$

band 损失:

$$L_{i,b} = \frac{1}{N_{i,b}} \sum \rho\left((Y_i - \hat{Y}_i) \odot M_{i,b}\right)$$

router 驱动的 band 加权:

$$L_{aux,i} = \sum_{b=1}^{B} w_{i,b} L_{i,b}$$

其中 $w_{i,b} = \mathrm{Blend}\left(r_{i,b}^{\mathrm{router}}, \bar{w}_b^{\mathrm{global}}\right)$

总结步骤

1. 把未来预测窗口切成多个时间 band
2. 让 router 判断当前样本更偏向哪种时间尺度
3. 用 router 权重动态调节不同 band 的损失占比
4. 让模型学到样本级的时间尺度自适应预测策略

3.6 Step 6：推理阶段的自适应 guidance

核心思想

router 输出不会只用于训练，还会继续**参与推理控制**。

- 首先将 band 权重分布压缩成一个**样本级尺度分数**
- 再根据该尺度分数对**基础 guide weight**做样本级调整
- 从而实现不同样本对**文本条件依赖程度**的动态调节

核心公式

尺度分数：

$$\sigma_i = \sum_{b=1}^{B} r_{i,b}^{router} m_b$$

样本级 guidance：

$$g_i = g \cdot clip(1 + \alpha(\sigma_i - 0.5), \rho_{min}, \rho_{max})$$

符号解释

σ_i

样本级尺度分数

g

基础 guide weight

g_i

样本级自适应 guidance 强度

$\alpha, \rho_{min}, \rho_{max}$

调节参数和裁剪边界

核心洞察

guidance 不应该是固定常数。**长期结构明显的样本**可以更依赖文本条件，**短期扰动明显的样本**则需要更保守的文本修正。